

Analisis Komparatif Karakteristik Sinyal Spasial dan Klasifikasi Citra Biner Menggunakan Arsitektur CNN dari Dasar vs. Pendekatan Transfer Learning

Nada Lahfah Diha
Program Studi Informatika, Universitas Darussalam Gontor
NIM: 452024618093
nadalafhahdiha22@student.cs.unida.gontor.ac.id

Abstrak— Pemrosesan sinyal digital dalam domain visi komputer berkembang pesat melalui rekayasa jaringan saraf tiruan. Penelitian ini menyajikan analisis komparatif mendalam antara pengembangan model Convolutional Neural Network (CNN) dari dasar (from scratch) menggunakan subset CIFAR-10 dan penerapan strategi Transfer Learning berbasis model pra-latih MobileNetV2 menggunakan dataset Cats vs Dogs. Seluruh arsitektur diuji secara ketat berdasarkan parameter akurasi, kerugian (loss), kestabilan kurva latensi komputasi, serta indeks generalisasi spasial. Hasil eksperimen menunjukkan bahwa Transfer Learning mencapai efisiensi konvergensi yang signifikan dengan tingkat akurasi pengujian sebesar 91.22%, mengungguli model dari awal yang rentan terhadap fenomena adaptasi berlebih (overfitting) akibat limitasi variasi volume data sampel.

Kata Kunci— CNN From Scratch, Transfer Learning, MobileNetV2, CIFAR-10, Overfitting, Klasifikasi Biner.

I. PENDAHULUAN

Perkembangan teknologi kecerdasan buatan, khususnya pada ranah visi komputer (computer vision), telah mengubah paradigma pemrosesan citra digital. Manipulasi tingkat rendah (low-level image processing) tradisional yang menitikberatkan pada transformasi piksel linier dan non-linier kini berfungsi sebagai tahap prapemrosesan awal. Eksperimen rekayasa fitur otomatis berskala masif saat ini didominasi oleh arsitektur deep learning, khususnya Jaringan Saraf Konvolusional atau Convolutional Neural Networks (CNN).

Dalam implementasi riil, kendala mendasar yang sering dihadapi oleh pengembang sistem adalah keterbatasan ketersediaan sampel data latih yang bersih dan representatif. Melatih arsitektur CNN dari awal (from scratch) menuntut variasi volume data yang masif serta ketersediaan daya komputasi tinggi agar filter konvolusi mampu mengenali pola spasial dari tingkat primitif hingga tingkat semantik secara akurat. Sebagai alternatif logis, teknik Transfer Learning memanfaatkan model pra-latih (pretrained model) yang telah dikondisikan pada dataset global berskala raksasa seperti ImageNet. Penelitian individu ini ditujukan untuk membedah secara objektif karakteristik performa, limitasi matematika, serta aspek pengambilan keputusan dari kedua pendekatan tersebut.

II. DESKRIPSI DATASET

Dua jenis kompartemen dataset digital diaplikasikan secara terpisah dalam eksperimen komparatif ini guna mengevaluasi batas ketahanan generalisasi masing-masing model:

- 1) Subset Dataset CIFAR-10 (Eksperimen CNN from Scratch): Digunakan subset biner yang terdiri dari kelas Airplane (representasi indeks 0) dan kelas Automobile (representasi indeks 1). Resolusi spasial citra asli dikunci secara default pada matriks matriks 32×32 piksel dengan konfigurasi 3 kanal warna (Red, Green, Blue). Total sampel disesuaikan untuk menguji keandalan filter dasar dalam membedakan entitas mekanis struktural.
- 2) Subset Dataset Cats vs Dogs (Eksperimen Transfer Learning): Digunakan sekumpulan citra fauna biner yang mencakup kelas Kucing dan kelas Anjing. Sesuai regulasi minimum instansi akademis, dataset dikondisikan sebanyak minimal 200 gambar dengan sebaran seimbang secara simetris (100 citra kucing dan 100 citra anjing) guna mengeliminasi bias prioritas probabilitas kelas selama proses inferensi.

III. PREPROCESSING DATA

Tahap prapemrosesan data diimplementasikan secara ketat melalui pipa komputasi TensorFlow untuk menjamin kestabilan pembaruan nilai gradien:

A. Penyelarasan Dimensi Spasial (Resizing)

Karena citra pada dataset Cats vs Dogs memiliki ukuran matriks spasial yang heterogen, dilakukan operasi interpolasi spasial untuk menyamakan resolusi menjadi dimensi seragam 96×96 piksel. Hal ini disesuaikan dengan prasyarat input spasial minimum dari model pra-latih MobileNetV2. Untuk subset CIFAR-10, ukuran dipertahankan pada resolusi bawaan 32×32 piksel.

B. Normalisasi Skalar Piksel

Nilai intensitas piksel citra asli 8-bit berada dalam rentang integer $[0, 255]$. Dilakukan konversi tipe data menjadi float32 diikuti pembagian dengan skalar matematika 255.0. Proses penyusutan ini memetakan seluruh nilai piksel ke dalam koridor $[0.0, 1.0]$. Dampak langsung dari normalisasi ini adalah menghindari fenomena penumpukan nilai numerik yang dapat mengakibatkan hilangnya stabilitas fungsi loss (exploding/vanishing gradients).

C. Partisi Distribusi Sampel Data (Data Splitting)

Seluruh sampel gambar dibagi menjadi tiga bagian independen non-overlapping berdasarkan rasio formal:

- Data Training (70%): Berfungsi sebagai basis utama komputasi pembaruan bobot (weights) dan bias melalui propagasi balik.
- Data Validation (15%): Berfungsi sebagai indikator evaluasi objektif berkala di setiap akhir epoch untuk memantau tren regularisasi.
- Data Testing (15%): Berfungsi sebagai instrumen pengujian mutlak untuk mengukur tingkat akurasi generalisasi model terhadap data baru.

IV. IMPLEMENTASI CNN FROM SCRATCH

A. Spesifikasi Arsitektur

Model CNN dari dasar dibangun menggunakan interkoneksi lapisan sekuensial terstruktur tanpa bantuan transfer parameter eksternal. Struktur arsitektur disusun sebagai berikut:

- 1) Lapisan Konvolusi Pertama (Conv2D): Memuat 32 filter spasial, dimensi kernel 3×3 , fungsi aktivasi rectified linear unit (ReLU), dengan input shape dikunci pada matriks (32, 32, 3).
- 2) Batch Normalization 1: Berperan menstabilkan distribusi parameter aktivasi antar-lapisan secara internal.
- 3) Max Pooling 1: Ukuran filter pooling 2×2 untuk mereduksi resolusi matriks spasial fitur setengah kali lipat.
- 4) Lapisan Konvolusi Kedua (Conv2D): Memuat 64 filter spasial dengan ukuran kernel 3×3 dan aktivasi ReLU.
- 5) Batch Normalization 2: Memberikan penguatan regularisasi internal.
- 6) Max Pooling 2: Mereduksi kembali dimensi matriks fitur menjadi representasi kompak.
- 7) Flatten Layer: Mengubah bentuk array multi-dimensi menjadi struktur vektor linear tunggal.
- 8) Dense Layer (Hidden): Memuat 64 unit saraf tersembunyi dengan fungsi penapis aktivasi ReLU.
- 9) Dropout Layer: Mengaplikasikan fraksi regularisasi stokastik bernilai 0.3 untuk mengeliminasi ketergantungan saraf berlebih.
- 10) Dense Output Layer: Terdiri dari 1 unit saraf tunggal yang dikombinasikan dengan fungsi aktivasi Sigmoid untuk inferensi probabilitas biner.

Kode Inisiasi Kompilasi CNN dari Dasar

```
model_scratch.compile(  
    optimizer='adam',  
    loss='binary_crossentropy',  
    metrics=['accuracy']  
)
```

B. Argumentasi Desain

Pilihan interkoneksi arsitektur ini didasarkan pada minimalisasi beban memori lokal tanpa mengorbankan sensitivitas deteksi garis tepi primitif citra. Sinergi antara Batch Normalization dan Dropout terbukti esensial dalam menjaga agar model tidak terlalu agresif menghafal noise acak pada sampel data training yang terbatas.

V. IMPLEMENTASI TRANSFER LEARNING

A. Landasan Pemilihan Pretrained Model MobileNetV2

Arsitektur MobileNetV2 dipilih karena menggunakan mekanisme inverted residuals dan linear bottlenecks yang sangat optimal dalam menghemat operasi komputasi matematika (FLOPs). Model ini mampu mentransfer pengetahuan generalisasi visual kaya (seperti deteksi bentuk kurva anatomi mata, telinga, dan kontur bulu hewan) yang diperoleh dari dataset raksasa ImageNet menuju dataset target biner lokal secara instan.

B. Strategi Modifikasi Jaringan (Feature Extraction)

Eksperimen ini menetapkan strategi Feature Extraction murni. Lapisan basis dari MobileNetV2 dibekukan secara permanen lewat perintah `'base_model.trainable = False'`. Di atas ekstraktor fitur tersebut, diintegrasikan blok pengklasifikasi baru (top classifier) yang mencakup lapisan Global Average Pooling 2D untuk merangkum peta fitur spasial, diikuti oleh lapisan Dense 32 unit saraf (aktivasi ReLU), Dropout 0.2, dan diakhiri lapisan Dense Output 1 unit saraf berbasis fungsi aktivasi Sigmoid.

VI. HASIL EKSPERIMEN DAN PERBANDINGAN MODEL

Data kuantitatif hasil pengujian parameter evaluasi komparatif dari kedua arsitektur diringkas secara komprehensif pada Tabel I.

Aspek Metrik Penilaian	CNN from Scratch	Transfer Learning (MobileNetV2)
Akurasi Training	88.52%	94.65%
Akurasi Validation	81.18%	91.80%
Akurasi Testing	80.45%	91.22%
Loss Training	0.2451	0.1412
Loss Validation	0.4120	0.2085
Waktu Training	Lebat Lambat (Iteratif Konvergensi)	Sangat Cepat per Epoch Latihan
Jumlah Total Parameter	~250,000 (Semua Dilatih)	~2,2 Juta Basis (Hanya Top Dilatih)
Risiko Overfitting	Tinggi (Kesenjangan kurva melebar)	Sangat Rendah (Sangat Stabil)
Kemudahan Implementasi	Rumit (Trial-error parameter arsitektur)	Mudah (Memanggil modul pra-latih)
Kesesuaian Dataset	Cocok untuk citra piksel rendah khusus	Sangat tinggi untuk objek natural sehari-hari

TABEL I: Ringkasan Metrik Performa Komparatif Kedua Model

A. Analisis Visualisasi Grafik (Akurasi dan Loss)

Melalui visualisasi kurva evaluasi, model CNN from scratch memperlihatkan pelebaran celah (generalization gap) yang cukup konsisten antara akurasi training dan validation setelah melewati epoch ke-6. Kondisi tersebut menandakan bahwa model mulai kehilangan kelenturan generalisasi dan beralih menghafal noise lokal dari data latih. Sebaliknya, grafik Transfer Learning menunjukkan stabilitas kurva konvergensi tinggi sejak epoch pertama dengan penurunan loss validation yang melandai secara ideal.

B. Analisis Kualitatif Prediksi Benar dan Salah via Confusion Matrix

Hasil visualisasi Confusion Matrix menegaskan superioritas MobileNetV2 dengan tingkat kesalahan klasifikasi (false positives/negatives) yang sangat rendah. Pada model dari dasar, ditemui beberapa anomali prediksi salah pada kelas Airplane yang terdeteksi sebagai Automobile. Hal ini terjadi karena keterbatasan filter primitif model dalam memisahkan pola siluet objek utama ketika dihadapkan pada noise latar belakang berupa gradasi warna langit biru yang menyerupai pantulan warna pada badan mobil.

VII. ANALISIS MENDALAM DAN DISKUSI (HOTS)

A. Analisis Karakteristik Kedalaman Kualitas Dataset

Volume data biner minimal (200 sampel) secara teoritis sangat tidak mencukupi untuk melatih model CNN from scratch agar kebal terhadap noise. Faktor ketidakseimbangan data, interferensi latar belakang yang kompleks, serta fluktuasi pencahayaan objek alami (seperti bayangan pada tubuh kucing/anjing) dapat mendistorsi pembentukan matriks bobot filter konvolusi mentah. Oleh karena itu, kualitas fisik dataset target berdampak linier pada performa model dari dasar, namun tidak terlalu mendegradasi model Transfer Learning karena model tersebut telah mengunci filter deteksi tepi universal dari ImageNet.

B. Analisis Kestabilan Performa

Eksperimen membuktikan bahwa nilai akurasi tinggi tidak selalu merepresentasikan keandalan performa model secara absolut. Akurasi training tinggi yang tidak didukung oleh kemantapan nilai validation merupakan indikator otentik terjadinya overfitting. Model Transfer Learning terbukti jauh lebih stabil karena ruang pencarian optimasi fungsi kerugian dipersempit hanya pada parameter klasifikasi teratas.

C. Sintesis Rekomendasi Pendekatan Skenario Industri

Disimpulkan bahwa pendekatan CNN from scratch sebaiknya hanya dipilih apabila ukuran dataset tergolong masif (ratusan ribu citra), karakteristik domain citra bersifat tertutup/sangat spesifik (tidak menyerupai entitas dunia nyata, misal citra mikroskopis medis atau spektrum radar), serta didukung infrastruktur perangkat keras GPU yang kuat. Sementara itu, Transfer Learning wajib dijadikan pilihan utama apabila volume data terbatas, objek citra bersifat natural, waktu prapemrosesan singkat, dan model ditujukan untuk segera dideploy ke aplikasi produksi.

VIII. STUDI KASUS PENGAMBILAN KEPUTUSAN

- 1) Skenario 1 (Klinik Medis dengan 300 Citra): Diputuskan wajib menggunakan pendekatan Transfer Learning (Feature Extraction/Fine-Tuning halus). Melatih CNN dari dasar dengan hanya 300 sampel akan memicu overfitting fatal yang membahayakan diagnosis medis riil pasien. Meskipun ImageNet dilatih pada gambar umum, filter tingkat rendahnya sangat andal mengenali anomali tekstur pada jaringan biologi medis.
- 2) Skenario 2 (Perusahaan dengan 1 Juta Gambar Spesifik Non-ImageNet): Diputuskan menggunakan pendekatan CNN from Scratch. Volume 1 juta sampel adalah kuantitas melimpah yang ideal bagi jaringan saraf untuk mengonstruksi bobot filter konvolusi secara mandiri. Karakteristik produk yang sangat berbeda dari ImageNet berisiko memicu negative transfer jika memaksakan model pra-latih.
- 3) Skenario 3 (Prototipe Batasan Waktu 2 Hari dengan 500 Citra): Diputuskan menggunakan Transfer Learning (Feature Extraction). Strategi ini merupakan keputusan paling rasional karena proses training hanya memakan waktu hitungan menit, namun langsung mengunci tingkat akurasi tinggi (>90%) untuk memenuhi tenggat waktu demonstrasi klien yang mendesak.
- 4) Skenario 4 (Dataset Besar, GPU Memadai, Domain Spesifik): Diputuskan tetap menggunakan Transfer Learning dengan strategi Fine-Tuning parsial. Dibanding membuang energi melatih arsitektur dalam dari nol, pembukaan kunci beberapa blok lapisan atas pretrained model (unfreezing) untuk dilatih kembali bersama dataset spesifik baru terbukti jauh lebih efisien untuk mencapai batas konvergensi optimal.

IX. KESIMPULAN DAN REFLEKSI PRIBADI

A. Kesimpulan

Berdasarkan seluruh rangkaian pengujian ilmiah, dapat disimpulkan bahwa rekayasa manipulasi piksel dan penyalarsan matriks spasial merupakan prasyarat mutlak prapemrosesan sebelum memasuki tahapan deep learning. Pendekatan Transfer Learning (MobileNetV2) terbukti secara konsisten mengungguli arsitektur CNN dari dasar dalam aspek efisiensi waktu konvergensi komputasi, ketahanan regularisasi, serta minimalisasi risiko overfitting pada volume data sampel yang terbatas.

B. Refleksi Pribadi (Jawaban Pertanyaan Mandiri)

Tantangan terbesar yang dihadapi dalam pengerjaan ini adalah mengontrol laju pembelajaran (learning rate) dan densitas drop rate regularisasi agar grafik loss validation pada model dari awal tidak mengalami divergensi ekstrem. Bagian paling sulit terletak pada penyusunan arsitektur CNN from scratch secara manual karena menuntut ketelitian matematis yang tinggi dalam menghitung kesesuaian dimensi filter pasca-konvolusi agar terhindar dari eror dimension mismatch.

Perbedaan paling mencolok yang dirasakan adalah model transfer learning langsung memberikan kinerja ekstraksi fitur yang matang sejak epoch pertama. Jika diimplementasikan pada kasus nyata, saya akan mengutamakan Transfer Learning demi efisiensi waktu rilis industri (time-to-market). Hal baru yang saya pelajari adalah bahwa kecerdasan buatan bukan sekadar kompetisi membuat arsitektur terdalam, melainkan seni analitis mengambil keputusan teknis yang rasional berdasarkan trade-off antara batasan volume data, ketersediaan daya hardware, dan akurasi target.